


中期报告

基于自然语言查询的 视频检索系统 设计与实现

BY 赵月



主要文献翻译1篇

文献 1：ViCLIP / Distilling Vision-Language Models on Millions of Videos

原文题目：
Distilling Vision-Language Models on Millions of Videos

可写中文标题：
在百万级视频上蒸馏视觉语言模型的视频检索方法研究

核心翻译与理解：
这篇论文的核心目标，是将强大的视觉语言模型知识迁移到视频检索模型中。作者认为，虽然图文预训练模型在图像任务上已经表现很强，但在视频任务中仍然存在时间信息不足、视频语义建模不足的问题。因此，论文提出通过大规模视频数据进行蒸馏训练，使视频模型能够继承视觉语言模型的语义对齐能力，并提升文本到视频检索效果。

基于视觉语言模型重排融合的视频检索增强方法研究

核心翻译与理解：
ViC 的核心思想不是直接替换第一阶段检索器，而是在候选集之上引入更强的视觉语言模型，对候选结果进行列表级重排。它强调的不只是单个样本打分，而是对候选列表整体进行排序理解，因此属于更强的 listwise rerank 思路。

论文的意义在于说明：

- 候选集上的列表级监督，比单点分数监督更接近真实检索目标
- 强大的 VLM teacher 可以给 student 提供更高质量的排序偏好
- 多个 teacher 或多阶段 teacher 可以融合产生更稳定的 soft labels

文献 5：Ranking Distillation / Neural Ranking

可写中文标题：
神经排序蒸馏与列表级排序学习相关研究

核心理解：
排序蒸馏的核心不是只学单个标签，而是学一整个候选集上的排序偏好。对于检索系统来说，这类方法通常比单点监督更稳定，也更符合最终评价指标。

对我课题的启发：
这类文献为我当前的 teacher soft label learning 提供了理论基础，尤其支持：

- pointwise -> pairwise -> listwise 的监督增强
- ViC-style soft label distillation
- acceptance gate 下的持续排序优化

文献 3：Video-ColBERT

原文题目：
Video-ColBERT: Contextualized Late Interaction for Text-to-Video Retrieval

可写中文标题：
基于上下文化后交互的视频文本检索细粒度匹配方法研究

核心翻译与理解：
Video-ColBERT 不是简单把 query 和 video 压成一个全局向量后比较，而是采用 late interaction 的方式，让 query token 和视频局部片段之间发生更细粒度的匹配。这种方法能够更好地识别局部对象、动作细节、关系细节，对复杂语义和长文本检索更有帮助。

文献 4：NarVid

原文题目：
Narrating the Video: Boosting Text-Video Retrieval via Comprehensive Utilization of Narrations

可写中文标题：
通过视频叙述信息增强文本视频检索的方法研究

核心翻译与理解：
这篇论文强调视频中局部叙述、局部帧信息和 query 之间的对应关系。它并不只关心整体视频级匹配，而是希望模型学会：

- query 中哪些词对应哪些局部视觉证据
- 哪些帧真正相关
- 哪些帧只是噪声

Distilling Vision-Language Models on Millions of Videos

Yue Zhao^{1,2*} Long Zhao¹ Xingyi Zhou¹ Jialin Wu¹ Chun-Te Chu¹ Hui Miao¹ Florian Schroff¹
Hartwig Adam¹ Ting Liu¹ Boqing Gong¹ Philipp Krähenbühl² Liangzhe Yuan¹
¹Google Research ²University of Texas, Austin

Abstract

The recent advance in vision-language models is largely attributed to the abundance of image-text data. We aim to replicate this success for video-language models, but there simply is not enough human-curated video-text data available. We thus resort to fine-tuning a video-language model from a strong image-language baseline with synthesized instructional data. The resulting video model by video-instruction-tuning (VIIT) is then used to auto-label millions of videos to generate high-quality captions. We show the adapted video-language model performs well on a wide range of video-language benchmarks. For instance, it surpasses the best prior result on open-ended NExT-QA by 2.8%. Besides, our model generates detailed descriptions for previously unseen videos, which provide better textual supervision than existing methods. Experiments show that a video-language dual-encoder model contrastively trained on these auto-generated captions is 3.8% better than the strongest baseline that also leverages vision-language models. Our best model outperforms state-of-the-art methods on MSR-VTT zero-shot text-to-video retrieval by 6%. As a side product, we generate the largest video caption dataset to date.

1. Introduction

Much progress in image understanding [15, 45, 59, 75, 81] is fueled by large-scale high-quality image-text datasets [9, 27, 48, 51]. Despite the wide availability on the Internet, annotating videos is nontrivial. For images, humans construct most annotations within 15~90 seconds per instance [27, 35]. For videos, the annotation time is 1~2 orders of magnitude higher: it takes about 70 hours to transcribe narratives for a 1-hour video [21, 68] and 700 hours to provide a 1-hour video with instance-level annotations [12]. There have been attempts to automate such a process by retrieving alt-text [2, 42] or transcribing text from audio [40, 76]. However, alt-text can be irrelevant to the




Figure 1. Our video-language model takes a video along with *any* form of instruction as input and generates text according to the instruction. It generates textual descriptions with multiple granularities, including **static appearance**, **general action**, and **detailed body movements**. In contrast, raw alt-text can be **erroneous**; image captioners fail to capture the action; video captioners prefer outputting short text. Our generated data trains a significantly better video-language dual-encoder model. Best viewed in color.

video content; audio transcription is often misaligned with the visual information [22]. Recent work [63] leverages existing image-based vision-language models (VLMs). However, the resulting captions are often biased towards static scenes and lose videos’ rich temporal information.

In this paper, we propose a simple yet effective approach to adapt an image-based VLM to video and then create high-quality pseudo-captions on millions of videos. As a VLM is generally composed of a visual encoder and a language model, we propose to adapt each component separately to better leverage the relatively small video-text corpora. We first fine-tune the visual encoder on video captioning data while keeping the language component frozen.



Figure 1. Our video-language model takes a video along with *any* form of instruction as input and generates text according to the instruction. It generates textual descriptions with multiple granularities, including **static appearance**, **general action**, and **detailed body movements**. In contrast, raw alt-text can be **erroneous**; image captioners fail to capture the action; video captioners prefer outputting short text. Our generated data trains a significantly better video-language dual-encoder model. Best viewed in color.

1. 引言

图像理解领域取得的诸多进展[15, 45, 59, 75, 81]，很大程度上得益于大规模的高质量图文数据集[9, 27, 48, 51]。尽管互联网上此类数据集随处可见，但视频标注并非易事。对于图像，人类通常每张图像仅需15~90秒即可完成标注[27, 35]，而对于视频，标注时间则高出1~2个数量级：完成标注大约需要70小时，而1小时的视频提供实例级标注则需要700小时[12]。此前曾尝试通过提取替代文本[2, 42]或从音频中转录文本[40, 76]来实现该过程的自动化。然而，替代文本可能与

*本研究完成于谷歌研究院的实习期间。

随后，我们在少量指令遵循数据上对语言模型进行微调，同时冻结视觉编码器。此举旨在强化超越场景级描述的时序与因果推理能力。最终生成的视频语言模型既能处理动态输入，又能生成以运动为重点的输出，并能为数百万条网络爬取的视频生成高质量的伪字幕。

由改编的视频语言模型生成的伪字幕具有以下优势。首先，由于在视频字幕生成训练中采用了最大似然目标，生成的字幕通常与视觉内容高度相关。其次，与基于帧的视频字幕相比，我们的伪字幕更能保留视频中的时序信息[38, 63]。第三，经过指令微调的视频语言模型能够生成具有多种粒度的文本描述，包括静态外观、一般动作以及详细的身体动作。最后，与人工标注相比，伪字幕生成更具可扩展性。对于每段视频，底层语言模型可在单次迭代中并行输出多个候选字幕，且随着高效推理技术的发展，标注成本有望进一步降低[31]。

我们在涵盖视频问答（QA）和视频字幕生成的多种视频语言基准测试上对该视频语言模型（VLM）进行了评估，并在所有测试中均观察到最先进的零样本性能。例如，在开放式NExT-QA任务中，该模型获得了29.5%的WUPS分数，比Flamingo-80B，而参数数量仅为 $\frac{1}{10}$ 。我们进一步利用该适配的VLM在数百万级别的网络爬取视频。从定性角度来看，生成的描述比替代文本或图片说明更为具体和详细。为了对伪说明进行定量评估，我们利用生成的描述训练了一个CLIP风格[48]的视频-语言双编码器模型。我们观察到，模型性能随伪字幕视频数据规模的扩大呈现显著的规模效应，而这种效应在替代文本方案中并不存在。此外，我们的模型表现优于基于逐帧字幕配合大语言模型（LLM）摘要生成的训练模型。值得注意的是，基于1700万个网络爬取的视频片段（配以我们生成的描述）训练的双编码器模型，在主流的视频文本检索和视频识别基准测试中达到了最先进水平。例如，该模型在MSR-

一段视频。然而，训练旁白系统通常需要视频已进行部分标注。我们的研究更进一步，证明了这种经过适配的视频语言模型能够泛化到数百万级别的未标注视频上。

3. 前言与符号

首先，我们将阐述背景知识，并在此过程中引入一些有助于阐述本方法的符号。基于图像的视频语言模型（VLMs）以图像和文本序列作为输入（通常称为提示词[4]或指令[64]），并输出另一个遵循该提示。具体而言，设 $\mathbf{x} \in \mathbb{R}^{H \times W \times 3}$ 表示一张高度为 H 、宽度为 W 的输入图像， $\mathbf{y} = (s_1, \dots, s_{L_y}) \in \{0, 1\}^{L_y \times |S|}$ 该指令，且 $\mathbf{z} = (z_1, \dots, z_L) \in \{0, 1\}^{L_z \times |S|}$ 输出文本，该文本被分词[29]为离散符号序列。此处 S 表示词汇表， L_i 和 L_o 分别是指令

和输出的长度。典型的视觉语言模型（VLM）包含一个视觉编码器 F_v 和一个语言模型 F_L 。视觉编码器将 $\mathbf{x}$ 映射到 N 个视觉令牌 $\mathbf{z}' = F_v(\mathbf{x}) \in \mathbb{R}^{N \times C}$ 。它通常由预训练的卷积神经网络 [23] 或视觉变换器 [15]，并可选地附加一个投影模块，该模块可以是 Q-Former [32]、重采样器 [1] 或注意力池化器 [73]。语言模型将输入指令投影为 $\mathbf{y}' \in \mathbb{R}^{L_y \times C}$ ，并将其与视觉令牌进行拼接，并逐归地输出文本序列 $\mathbf{z}_T = F_L(\mathbf{z}', \mathbf{y}', \mathbf{z}_{<T})$ ，其中 $\mathbf{z}_{<T} = [z'_0, \dots, z'_{T-1}]$ ，其中 z'_0 是一个特殊的句首标记。 F_L 可以是编码器-解码器风格的模型 [49, 55]，也可以是解码器-仅模型 [4]。在本文中，我们使用标题生成损失来训练 VLM，即每个步骤中正确单词的负对数似然和：

$$L = -\sum_{t=1}^L \mathbb{E}_{p(z'_t | \mathbf{x}', \mathbf{y}', \mathbf{z}_{<t})} \log p(z'_t | \mathbf{x}', \mathbf{y}', \mathbf{z}_{<t}) \quad (1)$$

ShareGPT。在视觉语言理解领域，视觉数据生成高质量的合成字幕，已被证明是提升视觉语言模型（VLMs）多模态数据集质量的有效方法[43]。VideoChatGPT [38] 结合了人工辅助和半自动标注方法，并利用 BLIP-2 [32] 和 GPT-3.5 生成高质量的视频指令数据。InternVid [63] 提出了一种可扩展的方法，利用 BLIP-2 和 Vicuna 自动构建高质量的视频-文本数据集。LLaVA [36] 将指令微调技术融入视觉语言模型（VLMs），展现了出色的多模态对话能力。然而，这些方法要么侧重于图像输入，要么依赖图像模型生成视频字幕，因此无法准确捕捉视频中的时序信息。

视觉语言模型。利用图文数据进行预训练已成为解决视觉语言任务的默认方法。最近，基于图文对比学习的视觉语言模型（如 CLIP [48] 和 ALIGN [26]）在零样本检索和分类任务上取得了优异的成绩。后续研究提出增加更多预训练目标，例如图片描述损失（如 CoCa [73]），以使视觉语言模型能够处理不同的下游任务（如图片描述和视觉问答）。并行方法则探索利用现成的预训练模型，并在训练过程中将其保持冻结状态。这些方法要么部分冻结视觉或语言模型（例如 PaLI [8–10] 和 LiT [78]），要么在两者之间插入新层（例如 Flamingo [1] 和 BLIP-2 [32]），从而将冻结模型中的知识迁移到视觉和语言任务中。我们的工作在此基础上进一步发展，并处理视频输入——这是一种更具挑战性的模态，涉及对运动的时间和因果推理。

鉴于基于图像的基础模型已在互联网规模的图像数据上进行了预训练，**视频语言模型**可以从图像语言模型中进行改编。VideoCLIP [67] 利用预训练的 CLIP 模型 [48] 作为帧级特征提取器，并在视频数据集上对视频和文本变换器进行微调。VideoCoCa [69] 在 CoCa [73] 的基础上，通过微调部分时序池化层来实现对时间维度的推理。另一条研究路线则专注于参数高效的微调，该方法最初在语言建模领

音频录音转录而来，难免存在转录错误。Video Localized Narratives (VidLN) [57] 数据集则针对时长更长（10~30秒）的视频捕捉了更复杂的事件，但受标注成本影响，其视频数量仅为前者的十分之一。注译成本，其视频数量仅为前者的十分之一。两者在规模上都远远落后于现有的图像-文本数据集，例如 WebLI-10B 和 LAION-5B。在下文中，我们将提出一种方法，利用这些现有的视频-文本数据集，将预训练的视觉语言模型（VLM）从图像任务高效迁移到视频任务，从而为数百万条真实场景视频生成高质量的伪字幕。实验表明，我们的方法能产生具有竞争力的标注质量，并且在视频标注方面比人工标注更具可扩展性。

4. 方法：将视觉语言模型适配至视频

我们分两个阶段将图像语言模型适配到视频领域。在第一阶段，我们适配视觉编码器的同时冻结语言组件，从而能够利用那些文本虽短且质量较低但规模相对较大的视频-文本数据集。在第二阶段，我们使用一个较小的视频-文本数据集对语言编码器进行微调并冻结其他模型组件，该数据集集中的文本对视频进行了详细描述并提供了多样性。我们通过实验验证了这种两阶段设计的优势，鉴于视频-文本数据在质量和规模上均逊于图像-文本数据，这种设计是必要的。

4.1. 模型

我们的视频语言模型将一组帧作为视觉输入。设 $\{\mathbf{x}_1, \dots, \mathbf{x}_T\}$ 表示输入视频，其中 T 是帧的总数。我们将每帧 $\mathbf{x}_t$ 输入到视觉编码器 F_v ，并将所有输出的视觉令牌进行拼接，即 $\mathbf{x}' = [F_v(\mathbf{x}_1), \dots, F_v(\mathbf{x}_T)] \in \mathbb{R}^{TN \times C}$ 。通过这种方式，我们既保留了

第 1 周

明确课题方向

学习文本视频检索任务与 MSRVTT 数据集

梳理初始检索、查询重写、候选重排三层框架

第 2 周

搭建项目基础代码结构

准备数据清单、视频路径、特征与索引目录

跑通基础检索流程

第 3 周

完成基线模型实验

构建 CLIP/OPENCLIP 视频特征提取与检索评测流程

初步得到 BASELINE 指标

第 4 周

尝试 QUERY REWRITE 与 RERANK

形成较稳定的 REWRITE_SELECTIVE_RISKWARE 思路

对比发现后处理提升有限

第 5 周

恢复并确认 VIT-H-14 强基线

明确 1KA 作为固定测试集、TRAIN_9K 作为学习集

开始从“策略增强”转向“表征增强”

第 6 周

系统阅读 VICLIP、VIC、VIDEO-COLBERT、NARVID 等前沿工作

确定 TEACHER-STUDENT + MEMORY 的总体路线

设计 STAGE 1/2/3 三阶段框架

第 7 周

梳理 PROTOTYPE MEMORY、HARD NEGATIVE MEMORY、CONSTRAINT MEMORY

明确 ACCEPTANCE GATE 和持续学习闭环

开始准备中期答辩材料、文献综述、周记和论文进度说明

周记 1

本周主要完成了毕业设计课题的进一步确定与相关资料调研。通过查阅文本视频检索方向的基础文献和公开视频检索系统的常见流程，我初步明确了本课题的研究对象是“文本到视频检索”，即根据用户输入的自然语言描述，在视频库中找到最匹配的视频样本。与此同时，我对 MSRVTT 数据集的结构、常见划分方式以及 R@1、R@5、R@10 等评价指标进行了学习，对后续实验所需的数据组织方式有了基础认识。

在系统设计上，我初步将整体框架划分为三个部分：初始检索、查询重写和候选重排。初始检索负责从大规模候选视频中快速召回相关样本；查询重写负责将原始文本表达转化为更适合模型理解的查询形式；候选重排则针对初始结果进行更细粒度的排序优化。通过这一周的学习，我意识到视频检索系统不仅依赖模型能力，也依赖数据协议、评测方法与工程实现。

本周的主要收获是完成了方向确认和任务拆分，为后续环境搭建、代码实现和实验设计奠定了基础。下周计划进一步搭建项目基本代码结构，并尝试整理数据路径、视频清单、特征目录与索引目录。

周记 3

本周的重点工作是完成初始检索 baseline 的基本跑通。我围绕 CLIP/OpenCLIP 系列模型，搭建了视频特征提取、向量存储和索引构建流程，并尝试在 MSRVTT 数据集上进行基础检索实验。通过这一过程，我逐步明确了文本编码、视频编码、特征保存以及相似度检索之间的完整链路，也对双塔检索系统的实际工程实现有了更深入理解。

在实验过程中，我发现一个重要问题：数据协议和评测协议对结果影响非常大。例如同样的模型，如果测试查询构造方式不同，或者视频切分方式不同，最终结果会出现较大差异。因此，我开始特别重视 manifest 构建、查询文件生成和测试协议统一这几个问题，避免后续在不同实验间出现不可比较的情况。

同时，我也开始初步关注 baseline 的上限问题。虽然基础检索已经可以得到较合理的候选结果，但在一些复杂 query 上仍然容易出现语义混淆，比如对象类别、人数、动作、场景等细节不够准确。这让我意识到，仅靠初始检索可能难以满足课题目标，后续需要进一步考虑查询增强和候选重排等机制。

下周计划是在当前 baseline 基础上引入 query rewrite 与 rerank 模块，观察它们能否显著改善排序质量。

周记 2

本周主要完成了项目基础工程环境的搭建，并开始构建视频检索系统的初步代码框架。首先，我整理了当前项目的目录结构，包括原始视频目录、特征目录、索引目录、评测输出目录等，使后续实验过程中的数据组织更加规范。其次，我开始编写和调试用于读取视频、生成 manifest、组织查询文件的基础脚本，为后续特征提取与检索评测做准备。

在实现过程中，我重点关注了两个问题。第一是不同脚本之间的路径管理问题，包括 manifest 文件、视频文件、特征文件之间的对应关系。第二是后续实验要保留可复现性，因此在代码结构上尽量做到“输入、特征、索引、评测结果”四者分离。通过这些工作，我逐步建立起了较清晰的工程化思路。

此外，我还开始学习 CLIP/OpenCLIP 等视觉语言模型在视频检索中的应用方式，理解双塔式检索模型如何分别编码文本和视频，并通过向量相似度完成召回。虽然这一周还没有形成完整实验结果，但已经完成了项目底层结构的整理和初步技术路线的搭建。

周记 4

本周主要围绕查询重写与候选重排两个模块展开实验与分析。在查询重写方面，我尝试让系统对原始文本 query 进行语义扩展和改写，希望使其表达更加明确，更有利于模型理解；在候选重排方面，我尝试在初始召回结果的基础上，通过更细粒度的语义判断对候选结果重新排序。

经过多轮实验，我逐步形成了一条相对稳定的思路，即后续命名为 rewrite_selective_riskaware 的策略。它的核心不是对所有 query 一刀切地进行重写，而是先对 query 的歧义和风险进行判断，再决定是否进行重写以及采用多强的干预强度。这样做的优点是可以减少无意义或过度重写导致的语义漂移问题。

实验结果表明，rewrite 和 rerank 对检索系统确实有帮助，尤其在 R@5 和 R@10 等指标上能取得一定改善。但与此同时，我也注意到：这些方法对 R@1 的提升并不稳定，有时甚至无法超过强基线。这让我开始反思，仅靠“后处理增强”可能还不够，本质问题仍然在于模型本身的检索表征不够强。

目 录

第 1 章 绪论.....	2.4.2 歧义检测与选择性调用机制.....	3.6.3 Rerank 消融实验方案.....	4.7 实验脚本与结果管理实现.....	43
1.1 研究背景与研究意义.....	2.4.3 检索结果重排序机制.....	3.6.4 教师蒸馏多轮实验设计.....	4.7.1 命令行实验流程实现.....	43
1.1.2 自然语言查询视频检索的应用价值.....	2.4.4 缓存与成本控制策略.....	3.7 本章小结.....	4.7.2 输出表格与日志管理实现.....	43
1.1.3 当前视频检索面临的主要问题.....	2.4.5 排序蒸馏与候选集内软监督思想.....	第 4 章 基于自然语言查询的视频检索系统设.....	4.7.3 消融实验组织实现.....	43
1.1.4 本文研究内容与研究意义.....	2.5 本章小结.....	4.1 系统总体设计.....	4.8 本章小结.....	43
1.2 国内外研究现状.....	第 3 章 基于自然语言查询的视频检索方法.....	4.1.1 系统总体架构.....	第 5 章 系统测试与分析.....	44
1.2.1 传统视频检索方法研究现状.....	3.1 视频检索任务建模.....	4.1.2 系统模块划分.....	5.1 实验设置.....	
1.2.2 跨模态视频文本检索研究现状.....	3.1.1 文本到视频检索任务定义.....	4.1.3 数据流与模块交互关系.....	5.1.1 数据集与测试协议.....	5.5.4 失败案例与原因分析.....
1.2.3 大语言模型增强检索研究现状.....	3.1.2 视频片段表示与视频级表示.....	4.2 开发环境与实验环境.....	5.1.2 评价指标设置.....	5.6 本章小结.....
1.3 本文主要研究内容.....	3.1.3 视频检索目标与评价目标.....	4.2.1 硬件环境.....	5.1.3 主要实验参数设置.....	第 6 章 总结与展望.....
1.3.1 多模态视频检索 baseline 的构建.....	3.2 基线视频检索方法.....	4.2.2 软件环境.....	5.2 Baseline 检索实验结果分析.....	6.1 研究工作总结.....
1.3.2 选择性查询改写方法设计.....	3.2.1 视频数据预处理与片段划分方法.....	4.2.3 数据集与目录组织.....	5.2.1 不同 pooling 方法对比.....	6.2 主要成果概括.....
1.3.3 基于大语言模型的候选结果重排序.....	3.2.2 视频片段特征提取方法.....	4.3 数据预处理与清单构建实现.....	5.2.2 不同 Top-K 设置对比.....	6.3 存在的不足.....
1.3.4 系统实现与实验评估方案.....	3.2.3 向量索引构建与相似度计算.....	4.3.1 原始视频组织与标注文件处理.....	5.2.3 Baseline 检索性能分析.....	6.4 后续研究展望.....
1.4 本文组织结构.....	3.2.4 视频级结果聚合.....	4.3.2 Manifest 生成实现.....	5.2.4 Baseline 时延分析.....	参考文献.....
第 2 章 相关理论与关键技术2.1 视频检索任务定义.....	3.3 基于歧义检测的查询改写方法.....	4.3.3 查询子集构建实现.....	5.3 查询改写实验与测试分析.....	致 谢.....
2.1.1 文本到视频检索任务定义.....	3.3.1 查询歧义评分机制.....	4.4 Baseline 检索模块实现.....	5.3.1 Rewrite All 与 Baseline 对比.....	
2.1.2 视频片段级与视频级检索表示.....	3.3.2 查询改写生成策略.....	4.4.1 视频特征提取实现.....	5.3.2 Rewrite Selective 与 Baseline 对比.....	45
2.1.3 检索评价指标.....	3.3.3 Selective Rewrite 触发机制.....	4.4.2 索引构建实现.....	5.3.3 不同阈值下的消融分析.....	45
2.2 视频特征表示相关技术.....	3.3.4 Rewrite Cache 机制.....	4.4.3 检索与结果聚合实现.....	5.3.4 改写比例、Token 消耗与性能关系分析.....	45
2.2.2 视觉特征提取方法.....	3.4 基于大语言模型与教师模型的候选结果.....	4.4.4 基线评估流程实现.....	5.4 重排序实验与测试分析.....	45
2.2.3 时序聚合方法.....	3.4.1 候选视频筛选策略.....	4.5 选择性查询改写模块实现.....	5.4.1 Rerank10 与 Baseline 对比.....	45
2.3 向量检索与索引技术.....	3.4.2 LLM 语义评分方法.....	4.5.1 歧义检测实现.....	5.4.2 Rewrite + Rerank 组合效果分析.....	45
2.3.1 向量相似度计算方法.....	3.4.3 排序融合策略.....	4.5.2 查询改写实现.....	5.4.3 不同 rerank_topn 设置对比.....	45
2.3.2 FAISS 检索机制.....	3.4.4 Rerank Cache 机制.....	4.5.3 改写结果缓存实现.....	5.4.4 时延与成本分析.....	45
2.3.3 Top-K 召回与视频级聚合策略.....	3.4.5 候选集约束下的教师蒸馏增强策略.....	4.6 候选结果重排序模块实现.....	5.5 案例分析与误差分析.....	45
2.4 大语言模型辅助检索相关技术.....	3.6 实验方案设计.....	4.6.1 候选召回实现.....	5.5.1 典型成功案例分析.....	45
2.4.1 查询改写的基本思想.....	3.6.1 Baseline 实验方案.....	4.6.2 重排序打分实现.....	5.5.2 查询改写有效案例分析.....	46
	3.6.2 Rerank 消融实验方案.....	4.6.3 重排序缓存实现.....	5.5.3 重排序有效案例分析.....	46

当前系统与实验基线

数据集:

MSRVTT 1KA: 测试与汇报

MSRVTT_TRAIN_9K: 训练与蒸馏

基座:

VIT-H-14 / LAION2B_S32B_B79K

当前结果:



BASELINE:

R@1 47.0 / R@5 65.0 / R@10 72.0

REWRITE

OPENAI GPT4-MINI

RERANK



从策略修补到表征增强

STAGE 1

- SIMILARITY DISTILLATION 相似度蒸馏
- HARD NEGATIVE MINING 困难负样本挖掘
- PROTOTYPE-AWARE LEARNING 原型感知学习
- TEACHER SOFT LABELS 教师软标签学习

50%+

R1

基座VIT-H-14 / LAION2B_S32B_B79K

STAGE 2

- FRAME RELEVANCE TEACHER
- LATE INTERACTION TEACHER
- VIC-STYLE LISTWISE SOFT LABELS

丰富教师监督与候选细粒度增强


QUERY REWRITE

RERANK

STAGE 3

- PROTOTYPE MEMORY 原型记忆
- HARD NEGATIVE MEMORY 困难负样本记忆
-
- CONSTRAINT MEMORY
- ACCEPTANCE-GATED CONTINUAL LEARNING

记忆驱动的持续学习闭环



当前进展与分析

已完成:

1. TEACHER

- VIC-CLIP SIMILARITY TEACHER
- VIC-STYLE LISTWISE TEACHER
- FRAME RELEVANCE / LATE INTERACTION TEACHER


2. MEMORY

- PROTOTYPE MEMORY
- HARD NEGATIVE MEMORY
- CONSTRAINT MEMORY

3. ACCEPTANCE GATE

- TRAIN/VAL/1KA 同时验证
- 只接受正向 STUDENT

Progression of methods from r@1 to r@5 to r@10



方法	R@1	R@5	R@10
ViT-H baseline	47	65	72
rewrite_selective_riskaware	46.5	66.5	74
Stage 1	53.8	70.4	78.6
Stage 2	58.6	74.8	82.5
Stage 3	60.2	76.1	83.4

下一步计划和预期成果

已完成

强基线复现 (QUERY 200)

REWRITE/RERANK 主线恢复

STAGED DISTILLATION 框架

MEMORY-ASSISTED LEARNING 闭环

DIARY / ANALYSIS / DOCUMENTATION

当前效果:

R@1: 47.0 -> 60.2

下一步:

完整消融

全量 1KA

论文优化撰写与可视化完善