


图5-X 不同检索路径的响应时间与调用成本对比



注：实验基于 MSR-VTT 1kA q200。Baseline 不调用大语言模型；Rewrite 与 Rerank 的成本主要来自 LLM 调用与候选语义比较。